Тюменский государственный университет ТюмГУ | ivideon

ЭТАПЫ ПРОЕКТА МАШИННОГО ОБУЧЕНИЯ

Приложение Б «Контрольный перечень для проекта машинного обучения»

Данил Зитцер (d.k.zitcer@utmn.ru)

СОДЕРЖАНИЕ

1. Проект машинного обучения целиком
2. Постановка задачи
3. Получение и исследование данных
4. Подготовка данных
5. Перспективные модели и точная настройка
6. Представление, запуск и сопровождение
7. Связь с практикой

01

ПРОЕКТ МАШИННОГО ОБУЧЕНИЯ ЦЕЛИКОМ

ВОСЕМЬ ШАГОВ ПРОЕКТА



CRISP-DM: ТОТ ЖЕ ЦИКЛ В ИНДУСТРИИ

- CRISP-DM — стандарт процесса анализа данных, конец 1990-х
- Понимание бизнеса — постановка задачи
- Понимание данных — получение и исследование
- Подготовка данных — подготовка данных
- Моделирование — выбор моделей и настройка
- Оценка и внедрение — представление и запуск

СКВОЗНОЙ ПРИМЕР: СЕТЬ СТРОЙМАТЕРИАЛОВ

- Десятки магазинов и складов
- Десятки тысяч товаров: цемент, краски, крепёж
- Прогноз продаж каждого товара в каждом магазине
- Горизонт — 1 месяц вперёд, обновление раз в месяц
- Прогноз нужен для закупок у поставщиков

02

ПОСТАНОВКА ЗАДАЧИ

БИЗНЕС-ЦЕЛЬ И ИСПОЛЬЗОВАНИЕ РЕШЕНИЯ



ТЕКУЩЕЕ РЕШЕНИЕ И ОПОРНЫЙ УРОВЕНЬ

- Сейчас: менеджеры считают заказ в таблицах
- Правило: продажи год назад × поправка
- Это опорный уровень (*baseline*)
- Модель нужна, только если она лучше
- Минимальная цель: ошибка на 15 % меньше

ФОРМУЛИРОВКА ЗАДАЧИ

- Обучение с учителем: продажи — готовые метки
- Регрессия: предсказываем число
- Точнее — прогноз временного ряда
- Пакетное обучение: переобучение раз в месяц
- Потока данных в реальном времени нет

МЕТРИКА КАЧЕСТВА И БИЗНЕС-ЦЕЛЬ

$$\text{WAPE} = \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i y_i}$$

- MAE несравнима между товарами
- WAPE — ошибка в долях от продаж
- Недопрогноз — пустая полка, клиент ушёл
- Перепрогноз — деньги заморожены на складе

АНАЛОГИ, ЭКСПЕРТЫ И ДОПУЩЕНИЯ

- Есть ли похожие задачи и готовые инструменты?
- Доступен ли опыт экспертов?
- Как решить задачу вручную?
- Записать допущения и проверить их

03

ПОЛУЧЕНИЕ ДАННЫХ

КАКИЕ ДАННЫЕ НУЖНЫ

- История продаж по чекам за 2–3 сезона и больше
- Остатки на складах, цены и скидки
- Календарь промо и праздников
- Погода: стройсезон зависит от неё
- Выгрузку автоматизировать с первого дня

ИСТОЧНИКИ, ПРАВА И ХРАНИЛИЩЕ

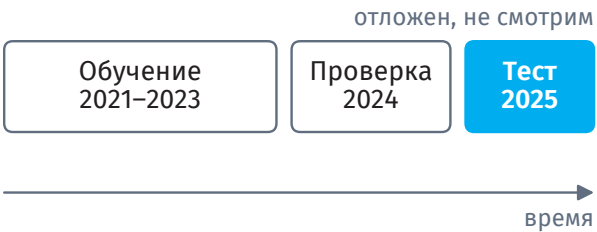
- Найти и документировать источники
- Оценить объём, создать рабочее пространство
- Выяснить правовые ограничения и получить доступ
- Привести к удобному формату, не меняя исходники

КОНФИДЕНЦИАЛЬНОСТЬ И ТИП ДАННЫХ

- В чеках — карты лояльности и телефоны
- Для прогноза по товарам они не нужны
- Удалить или обезличить до анализа
- Тип данных — временные ряды

ТЕСТОВЫЙ НАБОР: ДЕЛЕНИЕ ПО ВРЕМЕНИ

- Отложить сразу и не смотреть
- Случайное разбиение подсматривает будущее
- Обучение — старые месяцы
- Тест — самые свежие



04

ИССЛЕДОВАНИЕ ДАННЫХ

ПОРЯДОК ИССЛЕДОВАНИЯ

- Позвать экспертов: менеджеров категорий
- Работать с копией, при нужде — с выборкой
- Вести записи в блокноте Jupyter
- Определить целевой атрибут: продажи за месяц

КАРТОЧКА АТРИБУТА

- Имя и тип
- Доля пропусков
- Шум: выбросы, ошибки округления
- Польза для задачи
- Тип распределения

ПРОДАЖИ ПО МЕСЯЦАМ

- Годовая сезонность: пик летом
- Зимой — провал
- Общий тренд роста
- Шум и выбросы поверх



СВЯЗИ, РУЧНОЙ ПРОГНОЗ, ДОКУМЕНТАЦИЯ

- Связи: цена, промо, сопутствующие товары
- Ручной способ: «как год назад с поправкой»
- Отсюда первый признак — продажи год назад
- Записать всё найденное

05

ПОДГОТОВКА ДАННЫХ

КОПИИ И ФУНКЦИИ

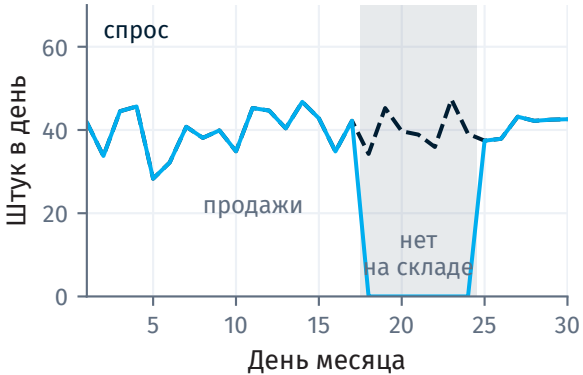
- Исходные данные не трогать
- Каждое преобразование — функция
- Повторить на свежих данных и тесте
- Применять к новым данным после запуска
- Варианты подготовки — гиперпараметры

ОЧИСТКА ДАННЫХ

- Выбросы: исправить или удалить
- Пропуски: заполнить или отбросить
- Ненужные атрибуты — отбросить

НУЛЕВЫЕ ПРОДАЖИ: СПРОС НЕ НУЛЕВОЙ

- Товар кончился — продаж нет
- А покупатели были
- Модель занизит прогноз
- Порочный круг дефицита



КОНСТРУИРОВАНИЕ ПРИЗНАКОВ

- Лаги: продажи месяц и год назад
- Скользящие средние за 3 и 12 месяцев
- Календарь: месяц, праздники
- Промо и цена
- Агрегаты по категории и магазину

МАСШТАБИРОВАНИЕ И УТЕЧКА ДАННЫХ

- Масштабирование: стандартизация, нормализация
- Утечка — признак из будущего
- Среднее, захватившее прогнозный месяц
- Промо, утверждённое после заказа
- Масштаб, посчитанный вместе с тестом

06

ПЕРСПЕКТИВНЫЕ МОДЕЛИ

МНОГО БЫСТРЫХ МОДЕЛЕЙ

- Модели разных классов со стандартными параметрами
- Линейная, SVM, случайный лес, бустинг, нейросеть
- Огромные данные — подвыборка
- Но подвыборка штрафует сложные модели
- Всё автоматизировать

ОПОРНАЯ МОДЕЛЬ ОБЯЗАТЕЛЬНА

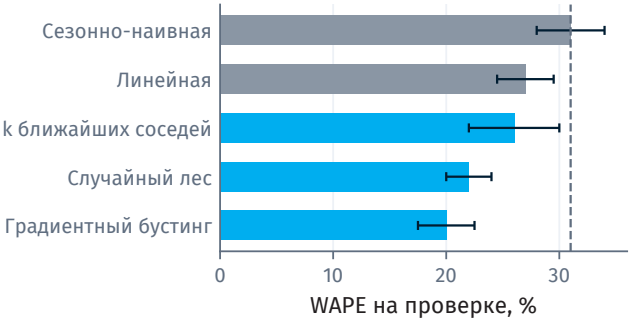
- Сезонно-наивный прогноз
- «Продажи как в том же месяце год назад»
- Ноль обучения, ноль признаков
- Не обыграли — ищите ошибку

ПЕРЕКРЁСТНАЯ ПРОВЕРКА ДЛЯ РЯДОВ



СРАВНЕНИЕ МОДЕЛЕЙ

- Среднее и разброс по блокам
- Разброс важен не меньше среднего
- Опорная модель — точка отсчёта
- В список — 3–5 лучших



ОШИБКИ И КОРОТКИЙ СПИСОК

- Какие признаки важны каждой модели?
- Где модели ошибаются: новинки, промо
- Что помогло бы человеку не ошибиться?
- Быстрый цикл признаков и повтор
- 3–5 моделей с разными ошибками

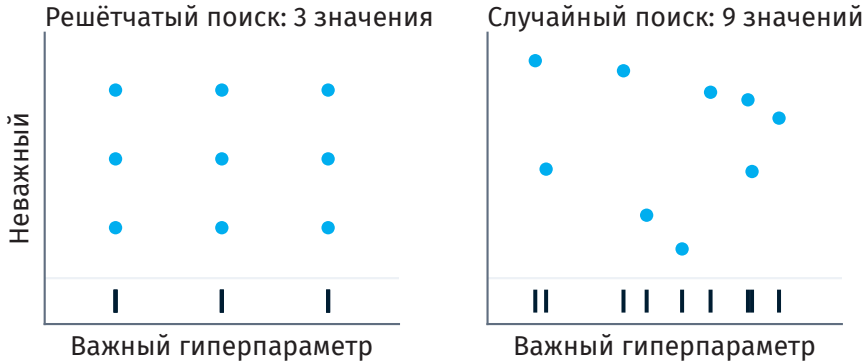
07

ТОЧНАЯ НАСТРОЙКА

ГИПЕРПАРАМЕТРЫ, ВКЛЮЧАЯ ПОДГОТОВКУ

- Настройка с перекрёстной проверкой
- Чем заполнять пропуски: нулём или медианой?
- Окно скользящего среднего: 3 или 6 месяцев?
- Решает перебор, а не интуиция
- Данных — как можно больше

СЕТКА, СЛУЧАЙНЫЙ ПОИСК, БАЙЕСОВСКИЙ



АНСАМБЛИ

- Комбинация моделей часто лучше каждой
- Особенно при разных ошибках
- Пример: бустинг + сезонно-наивная

ИТОГОВАЯ ОЦЕНКА НА ТЕСТЕ

- Один раз, когда модель выбрана
- Оценка ошибки обобщения
- После теста модель не подстраивают
- Иначе — переобучение на тесте

08

ПРЕДСТАВЛЕНИЕ РЕШЕНИЯ

ДОКУМЕНТ И ПРЕЗЕНТАЦИЯ

- Документировать всё сделанное
- Начать с общей картины
- Почему решение достигает бизнес-цели
- Что работает, а что нет

ОГРАНИЧЕНИЯ И ГЛАВНАЯ ФРАЗА

- Допущения и ограничения — честно
- Выводы — графиком или короткой фразой
- «На 30 % точнее ручного прогноза в сезон»
- «Новинки моложе 3 месяцев — вручную»

09

ЗАПУСК И СОПРОВОЖДЕНИЕ

ПОДГОТОВКА К ПРОДАКШЕНУ

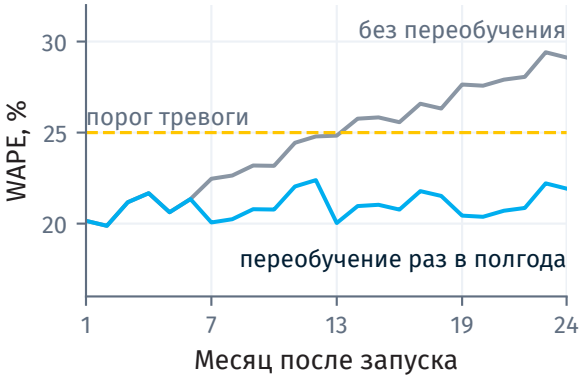
- Подключить рабочие источники данных
- Модульные тесты
- Автозапуск раз в месяц
- Те же функции подготовки
- Прогноз — в систему заказа

НАБЛЮДЕНИЕ ЗА СИСТЕМОЙ

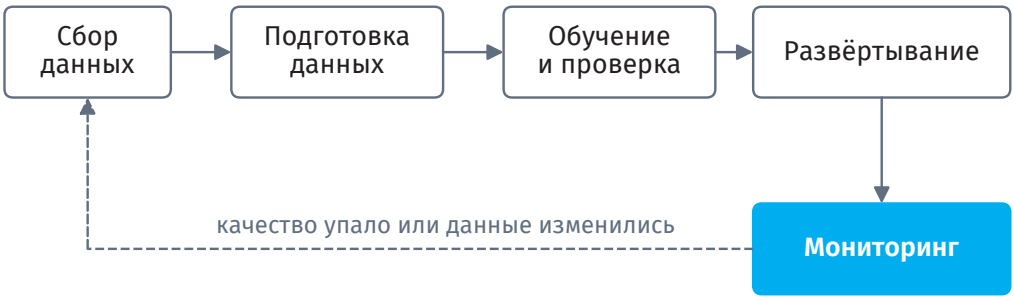
- Регулярно мерить реальное качество
- Тревога при падении
- Факт продаж приходит через месяц
- Следить и за входом: пропали чеки магазина

ДЕГРАДАЦИЯ И ПЕРЕОБУЧЕНИЕ

- Данные меняются — модель «портится»
- Дрейф: цены, ассортимент, конкуренты
- Переобучать на свежих данных
- Автоматизировать переобучение



ЦИКЛ MLOPS


Сбор данных
Подготовка данных
Обучение и проверка
Развёртывание
качество упало или данные изменились
Мониторинг

10

СВЯЗЬ С ПРАКТИКОЙ

ПЕРЕЧЕНЬ НА ПРАКТИКЕ

- Занятие 03 «Полный проект: данные и разведочный анализ»
- Занятие 04 «Полный проект: подготовка данных, модель, настройка»
- Занятие 11 «Практикум: табличная задача целиком»
- Совет: держать приложение Б открытым

11

ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. Назовите восемь шагов проекта. Какие повторяются по циклу?
2. Зачем выяснять использование прогноза до выбора метрики?
3. Что такое опорный уровень в прогнозе продаж?
4. Почему для рядов нельзя случайно делить данные?
5. Почему нулевые продажи — не всегда нулевой спрос?
6. Что такое утечка данных? Два примера.
7. Почему после теста модель не подстраивают?
8. За чем наблюдать после запуска?

СПАСИБО ЗА ВНИМАНИЕ!

Данил Зитцер (d.k.zitcer@utmn.ru)



ivideon