Тюменский государственный университет ТюмГу | ivideon

ОБУЧЕНИЕ ЛИНЕЙНОЙ РЕГРЕССИИ

Лекция 04. Глава 4 «Обучение моделей»

Данил Зитцер (d.k.zitcer@utmn.ru)

СОДЕРЖАНИЕ

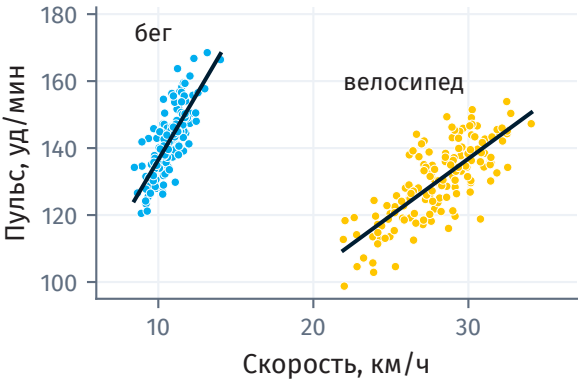
1. Постановка задачи
2. Аналитическое решение через частные производные
3. Нормальное уравнение
4. Градиентный спуск
5. Тонкости градиентного спуска
6. Итоги

01

ПОСТАНОВКА ЗАДАЧИ

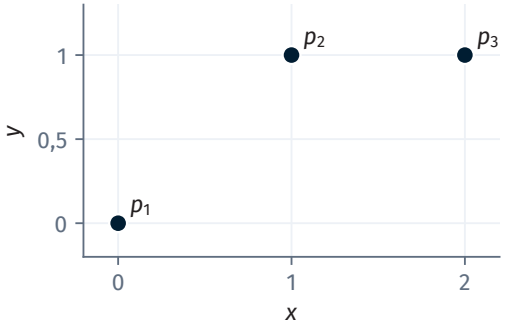
РЕГРЕССИЯ В ЖИЗНИ: ПУЛЬС И СКОРОСТЬ

- Как пульс спортсмена зависит от скорости бега и езды на велосипеде?
- Точка — одна тренировка, прямая — прогноз пульса для любой скорости
- Подобрать прямую по точкам — задача линейной регрессии



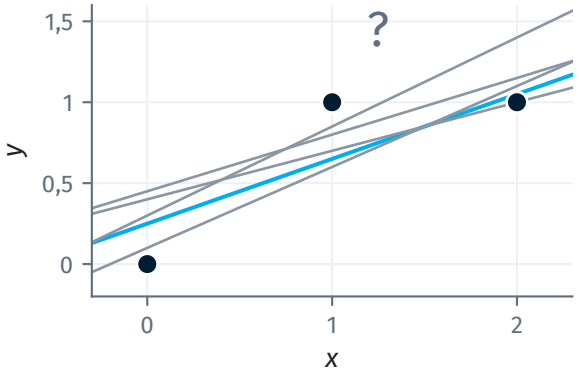
СКВОЗНАЯ ЗАДАЧА: ТРИ ТОЧКИ

Точка	x	y
p_1	0	0
p_2	1	1
p_3	2	1



КАКУЮ ПРЯМУЮ ВЫБРАТЬ?

- Прямых рядом с точками бесконечно много, и все они где-то ошибаются
- Чтобы выбрать лучшую, нужна числовая мера «близости» прямой к точкам



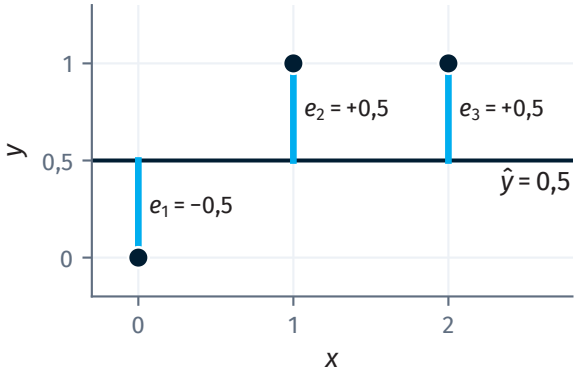
МОДЕЛЬ: УРАВНЕНИЕ ПРЯМОЙ

$$\hat{y} = ax + b$$

- x — известный вход (признак), $\hat{y}$ — прогноз модели, «игрек с крышечкой»
- a — наклон: на сколько меняется прогноз при росте x на единицу
- b — свободный член: значение прогноза при $x = 0$, сдвиг прямой по вертикали
- В книге та же модель записана как $\hat{y} = \theta_0 + \theta_1 x_1$, где $b = \theta_0$, $a = \theta_1$

ПЕРВАЯ ПОПЫТКА: ГОРИЗОНТАЛЬНАЯ ПРЯМАЯ

- Простейшая прямая $\hat{y} = 0{,}5$: наклон $a = 0$, сдвиг $b = 0{,}5$
- Голубые отрезки — промах прогноза в каждой точке
- Промах меряем по вертикали, а не по перпендикуляру к прямой



ОСТАТОК: ОШИБКА В ОДНОЙ ТОЧКЕ

$$e_i = y_i - \hat{y}_i$$

- Остаток — разница между настоящим значением и прогнозом в точке с номером i
- Для прямой $\hat{y} = 0{,}5$: $e_1 = 0 - 0{,}5 = -0{,}5$, $e_2 = 1 - 0{,}5 = 0{,}5$, $e_3 = 0{,}5$
- Знак остатка показывает, где точка: выше прямой — плюс, ниже прямой — минус
- Если прямая проходит точно через точку, остаток в ней равен нулю

ПОЧЕМУ СУММА КВАДРАТОВ, А НЕ ПРОСТО СУММА

$$\sum e_i = -0{,}5 + 0{,}5 + 0{,}5 = 0{,}5 \qquad \sum e_i^2 = 0{,}25 + 0{,}25 + 0{,}25 = 0{,}75$$

- Простая сумма обманывает: остатки разных знаков гасят друг друга
- Сумма квадратов равна нулю только у идеальной прямой
- Квадрат штрафует большие промахи сильнее: остаток 3 даёт 9, остаток 1 — всего 1
- У модуля $|e|$ излом в нуле, а квадрат гладкий и легко дифференцируется

МЕТОД НАИМЕНЬШИХ КВАДРАТОВ

$$S = \sum_{i=1}^{m} \left(y_i - \hat{y}_i\right)^2 \to \min \qquad \text{MSE} = \frac{1}{m} S$$

- Метод наименьших квадратов (МНК): лучшая прямая — та, у которой сумма квадратов остатков S наименьшая
- Книга минимизирует MSE — среднее квадратов; деление на число образцов m не сдвигает минимум
- RMSE из главы 2 — корень из MSE; минимум у них тоже общий, но MSE проще дифференцировать

ФУНКЦИЯ ОШИБКИ ДЛЯ ТРЁХ ТОЧЕК

$$S(a, b) = (0 - b)^2 + (1 - a - b)^2 + (1 - 2a - b)^2$$
$$= 5a^2 + 6ab + 3b^2 - 6a - 4b + 2$$

- Подставили координаты трёх точек: неизвестными остались только a и b
- Задача: найти a и b, при которых $S(a, b)$ принимает наименьшее значение
- Проверка: при $a = 0$, $b = 0{,}5$ получаем $S = 0{,}75$, как у горизонтальной прямой

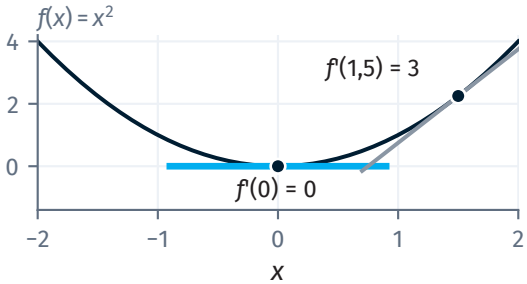
02

АНАЛИТИЧЕСКОЕ РЕШЕНИЕ ЧЕРЕЗ ЧАСТНЫЕ ПРОИЗВОДНЫЕ

ЭКСТРЕМУМ ФУНКЦИИ ОДНОЙ ПЕРЕМЕННОЙ

$$f'(x_0) = 0 \qquad f''(x_0) > 0$$

- Необходимое: в минимуме касательная горизонтальна
- Достаточное: $f'' > 0$, функция выпукла вниз
- У x^2: $f' = 2x = 0$ при $x = 0$, $f'' = 2 > 0$



ЭКСТРЕМУМ ФУНКЦИИ НЕСКОЛЬКИХ ПЕРЕМЕННЫХ

$$\frac{\partial S}{\partial a} = 0, \quad \frac{\partial S}{\partial b} = 0 \qquad H = \begin{pmatrix} S_{aa} & S_{ab} \\ S_{ab} & S_{bb} \end{pmatrix} = \begin{pmatrix} 10 & 6 \\ 6 & 6 \end{pmatrix}$$

- Частная производная по a — скорость изменения S, когда меняется только a
- Необходимое условие: все частные производные одновременно равны нулю
- Достаточное: гессиан H положительно определён, $S_{aa} > 0$ и $\det H > 0$
- У нашей S: $10 > 0$ и $10 \cdot 6 - 6^2 = 24 > 0$ — это будет минимум

ПРОИЗВОДНАЯ ПО НАКЛОНУ

$$\frac{\partial S}{\partial a} = 0 + 2(1 - a - b) \cdot (-1) + 2(1 - 2a - b) \cdot (-2)$$

$$= -2 + 2a + 2b - 4 + 8a + 4b = 10a + 6b - 6$$

$$10a + 6b - 6 = 0 \quad \Rightarrow \quad 5a + 3b = 3$$

- Дифференцируем каждый квадрат по правилу цепочки: $\left(u^2\right)' = 2u \cdot u'$
- Первое слагаемое b^2 не содержит a, поэтому его производная по a равна нулю

ПРОИЗВОДНАЯ ПО СВОБОДНОМУ ЧЛЕНУ

$$\frac{\partial S}{\partial b} = 2b + 2(1 - a - b) \cdot (-1) + 2(1 - 2a - b) \cdot (-1)$$

$$= 2b - 2 + 2a + 2b - 2 + 4a + 2b = 6a + 6b - 4$$

$$6a + 6b - 4 = 0 \quad \Rightarrow \quad 3a + 3b = 2$$

- Теперь фиксируем a; производная b^2 по b равна $2b$, у обеих скобок множитель –1

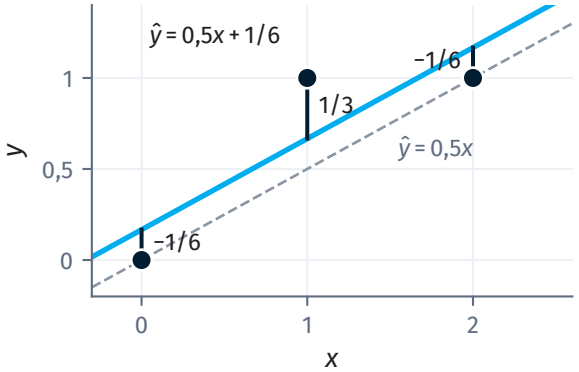
РЕШАЕМ СИСТЕМУ УРАВНЕНИЙ

$$\begin{cases} 5a + 3b = 3 \\ 3a + 3b = 2 \end{cases} \quad \Rightarrow \quad 2a = 1 \quad \Rightarrow \quad a = 0{,}5, \quad b = \frac{2 - 1{,}5}{3} = \frac{1}{6}$$

- Вычитаем второе уравнение из первого: слагаемые с b сокращаются, остаётся $2a = 1$
- Подставляем $a = 0{,}5$ во второе уравнение: $3b = 2 - 1{,}5 = 0{,}5$, отсюда $b = 1/6 \approx 0{,}167$
- Лучшая по МНК прямая: $\hat{y} = 0{,}5x + 1/6$; гессиан положительно определён — это минимум

НАЙДЕННАЯ ПРЯМАЯ

- Прямая не проходит ни через одну точку, но $S = 1/6 \approx 0{,}167$ — минимум
- Прямая через p_1 и p_3 даёт $S = 0{,}25$, горизонтальная — 0,75



А ЕСЛИ ТОЧЕК МИЛЛИОН, А ПРИЗНАКОВ СОТНИ?

- Реальный набор — не три точки, а миллионы образцов и десятки или сотни признаков
- Выписывать сумму квадратов и дифференцировать её вручную по сотне параметров невозможно
- Нужна общая формула для любого числа образцов и признаков — её даёт матричная запись

03

НОРМАЛЬНОЕ УРАВНЕНИЕ

ВСЕ ТОЧКИ ОДНОЙ ЗАПИСЬЮ

$$\begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \hat{y}_3 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} \qquad \hat{y} = X\theta$$

- Каждая строка матрицы признаков X — один образец, каждый столбец — один признак
- Столбец из единиц отвечает за свободный член b: без него прямая прошла бы через начало координат
- Вектор параметров $\theta = (a, b)$; для n признаков в нём $n + 1$ число, и запись не меняется

ОШИБКА В МАТРИЧНОМ ВИДЕ

$$S(\theta) = (y - X\theta)^T(y - X\theta) = \sum_{i=1}^{m} e_i^2 \qquad \text{MSE}(\theta) = \frac{1}{m}S(\theta)$$

- $y - X\theta$ — вектор всех остатков сразу, по одному числу на образец
- Скалярное произведение вектора на себя — сумма квадратов его элементов, то есть наша S
- Формула одинакова для трёх точек и для миллиона образцов с сотней признаков

НОРМАЛЬНОЕ УРАВНЕНИЕ

$$\nabla_\theta S = -2X^T(y - X\theta) = 0 \quad \Rightarrow \quad X^T X\,\theta = X^T y \quad \Rightarrow \quad \hat{\theta} = \left(X^T X\right)^{-1} X^T y$$

- Та же идея, что и вручную: все частные производные приравниваем к нулю сразу, одним вектором
- Решение системы — формула для параметров в аналитическом виде, без итераций
- Нужна обратимость $X^T X$: признаки не должны линейно выражаться друг через друга

ПОДСТАВЛЯЕМ ТРИ ТОЧКИ

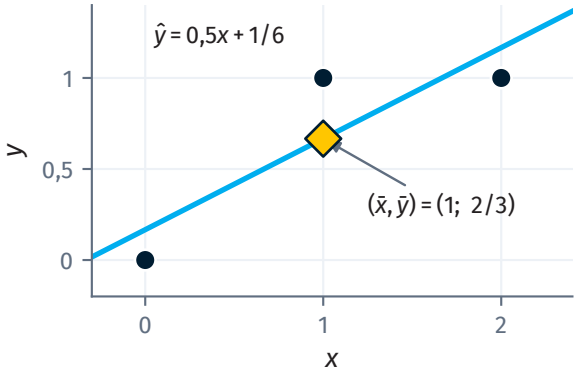
$$X^T X = \begin{pmatrix} 5 & 3 \\ 3 & 3 \end{pmatrix} \qquad X^T y = \begin{pmatrix} 3 \\ 2 \end{pmatrix} \qquad (X^T X)^{-1} = \frac{1}{6}\begin{pmatrix} 3 & -3 \\ -3 & 5 \end{pmatrix}$$

$$\hat{\theta} = \frac{1}{6}\begin{pmatrix} 3 & -3 \\ -3 & 5 \end{pmatrix}\begin{pmatrix} 3 \\ 2 \end{pmatrix} = \frac{1}{6}\begin{pmatrix} 3 \\ 1 \end{pmatrix} = \begin{pmatrix} 0{,}5 \\ 1/6 \end{pmatrix}$$

- Система $X^T X\,\theta = X^T y$ — это ровно наши уравнения $5a + 3b = 3$ и $3a + 3b = 2$

ОТВЕТ СОВПАЛ

- Та же прямая $\hat{y} = 0{,}5x + 1/6$, что и при ручном решении
- Прямая МНК всегда проходит через точку средних $(\bar{x}, \bar{y})$



ЦЕНА НОРМАЛЬНОГО УРАВНЕНИЯ

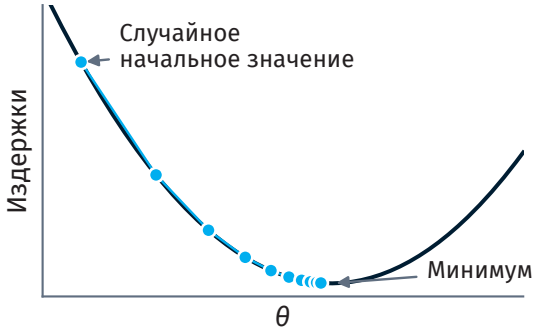
- Нужно обратить матрицу X^TX размером $n \times n$; это стоит от $O(n^{2,4})$ до $O(n^3)$ операций
- Удвоили число признаков — время выросло в 5,3–8 раз; при 100 000 признаков считать очень долго
- По числу образцов m сложность линейна, но вся матрица X должна поместиться в память
- Прогноз обученной моделью быстрый при любом способе обучения: время линейно по m и n

04

ГРАДИЕНТНЫЙ СПУСК

ДРУГОЙ ПОДХОД: ИТЕРАТИВНЫЙ СПУСК

- Не решаем уравнение, а улучшаем параметры маленькими шагами
- Старт — случайные параметры, стоп — когда ошибка почти не меняется
- Как в тумане в горах: идём туда, где склон круче вниз



По рис. 4.3 книги (стр. 160)

ОТКУДА БЕРЁТСЯ КАСАТЕЛЬНАЯ

$$f'(x_0) = \lim_{x \to x_0} \frac{f(x) - f(x_0)}{x - x_0} \approx \frac{f(x) - f(x_0)}{x - x_0}$$

$$f(x) \approx f(x_0) + f'(x_0)(x - x_0)$$

- Производная — предел отношения приращения функции к приращению аргумента
- При x, близком к x_0, предел заменяем приближённым равенством
- Выражаем $f(x)$: вблизи x_0 функция почти совпадает с касательной

ПРОИЗВОДНАЯ ПОДСКАЗЫВАЕТ НАПРАВЛЕНИЕ

$$x^2 \approx 4 + 4(x - 2) = 4x - 4 \quad \text{вблизи } x_0 = 2$$

- Подставили в формулу касательной $f(x) = x^2$ и $x_0 = 2$
- Наклон касательной +4: функция растёт вправо, значит, идём влево



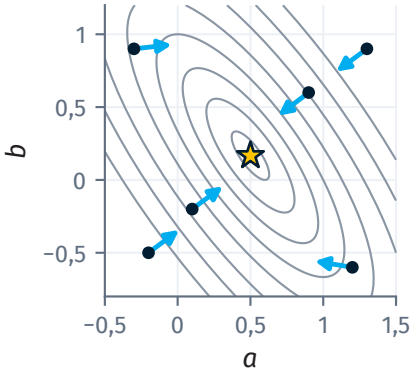
ШАГ ПРОТИВ ПРОИЗВОДНОЙ

$$x_{\text{след}} = x - \alpha f'(x) \qquad x_1 = 2 - 0{,}1 \cdot 4 = 1{,}6 \qquad f(1{,}6) = 2{,}56 < 4$$

- Знак производной показывает, куда функция растёт, поэтому шагаем в противоположную сторону
- Величина производной говорит о крутизне: чем ближе к минимуму, тем она меньше и тем короче шаг
- Множитель α — скорость обучения: гиперпараметр, который задаёт длину шага

ГРАДИЕНТ: ПРОИЗВОДНЫЕ ПО ВСЕМ ПАРАМЕТРАМ

- Градиент $\nabla S = (\partial S/\partial a,\ \partial S/\partial b)$ — вектор частных производных
- Он указывает, куда функция растёт быстрее всего; стрелки — антиградиент
- Он перпендикулярен линиям уровня S = const



ШАГ ГРАДИЕНТНОГО СПУСКА

$$\theta_{\text{след}} = \theta - \alpha \nabla S(\theta) \quad \Longleftrightarrow \quad \begin{cases} a_{\text{след}} = a - \alpha\, \partial S / \partial a \\ b_{\text{след}} = b - \alpha\, \partial S / \partial b \end{cases}$$

- Вычитаем градиент, умноженный на скорость обучения: идём вниз, против направления роста
- Обе производные считаем в одной и той же текущей точке (a, b), а потом обновляем оба параметра
- В книге скорость обучения обозначена η, а функция ошибки — MSE; суть формулы та же

ГРАДИЕНТ НАШЕЙ ФУНКЦИИ

$$\frac{\partial S}{\partial a} = 10a + 6b - 6 \qquad \frac{\partial S}{\partial b} = 6a + 6b - 4$$

- Это те же производные, что и в ручном решении, но теперь мы не приравниваем их к нулю
- Подставляем текущие a и b и получаем два числа — направление и крутизну склона в этой точке
- В точке $a = b = 1$: $\partial S/\partial a = 10$, $\partial S/\partial b = 8$ — обе положительны, оба параметра уменьшаем

ТРИ ШАГА ВРУЧНУЮ

$$a_1 = 1 - 0{,}1 \cdot 10 = 0 \qquad b_1 = 1 - 0{,}1 \cdot 8 = 0{,}2$$

Шаг	a	b	$\partial S/\partial a$	$\partial S/\partial b$	$S(a, b)$
0	1	1	10	8	6
1	0	0,2	−4,8	−2,8	1,32
2	0,48	0,48	1,68	1,76	0,426
3	0,312	0,304	−1,056	−0,304	0,245

- Старт $a = b = 1$, скорость обучения $\alpha = 0{,}1$; за три шага ошибка упала с 6 до 0,245

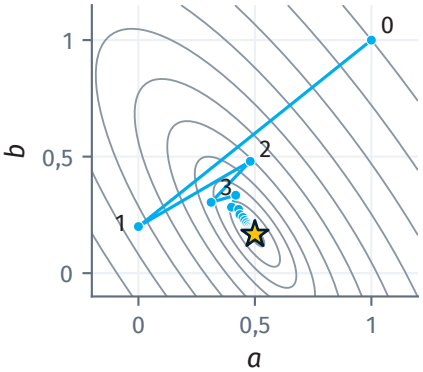
ПОСЛЕ 40 ШАГОВ

Шаг	a	b	$S(a, b)$
5	0,399	0,283	0,188
10	0,464	0,217	0,170
20	0,494	0,175	0,1667
40	0,500	0,167	0,1667

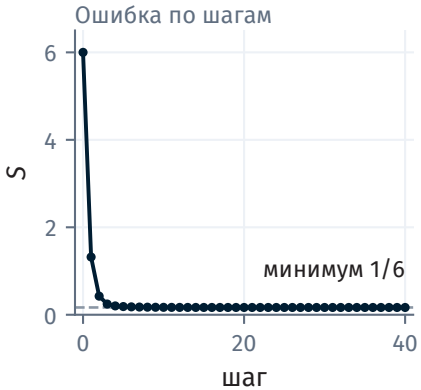
- Спуск пришёл к $a \approx 0{,}50$ и $b \approx 0{,}17$ — к тому же ответу, что и две формулы
- Градиент к 40-му шагу меньше 0,001: дальнейшие шаги почти ничего не меняют

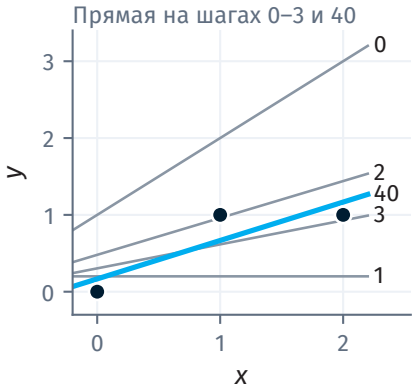
КАК ШЁЛ СПУСК: ПУТЬ ПАРАМЕТРОВ

- Точка — пара (a, b) после шага, старт в $(1, 1)$
- Первые шаги длинные и перескакивают дно «долины»
- Затем путь сворачивает к минимуму (0,5; 1/6)



КАК ШЁЛ СПУСК: ПРЯМАЯ И ОШИБКА

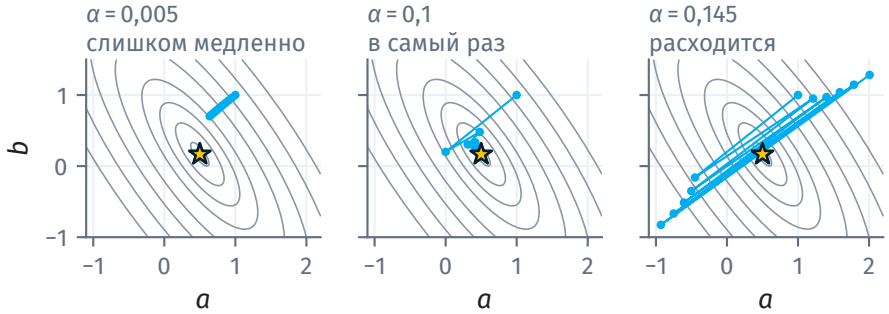




05

ТОНКОСТИ ГРАДИЕНТНОГО СПУСКА

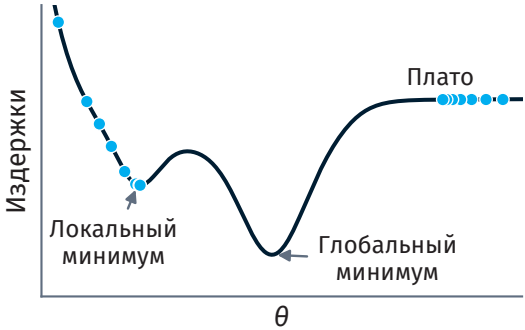
СКОРОСТЬ ОБУЧЕНИЯ: МАЛА, В САМЫЙ РАЗ, ВЕЛИКА



По рис. 4.8 книги (стр. 166)

ЛОКАЛЬНЫЕ МИНИМУМЫ И ПЛАТО

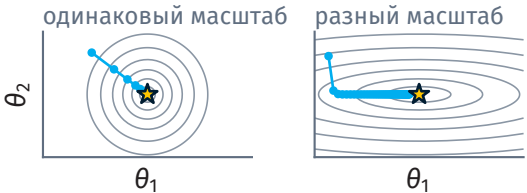
- Слева спуск застрял в локальном минимуме
- Справа на плато градиент почти нулевой, шаги крошечные
- MSE линейной регрессии выпукла: минимум один



По рис. 4.6 книги (стр. 162)

МАСШТАБ ПРИЗНАКОВ

- При разных масштабах признаков чаша вытянута
- Спуск долго бредёт по плоскому дну долины
- Перед спуском признаки стандартизируют



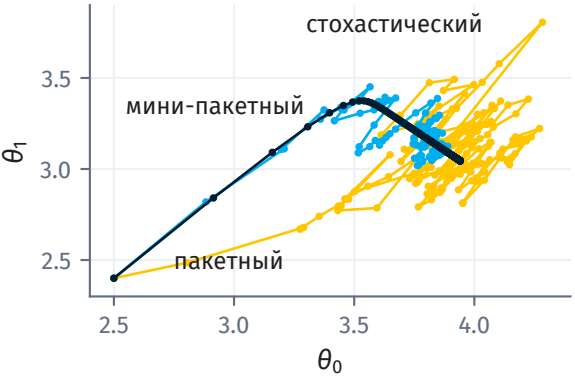
По рис. 4.7 книги (стр. 163)

ПАКЕТНЫЙ, СТОХАСТИЧЕСКИЙ И МИНИ-ПАКЕТНЫЙ

- Пакетный спуск считает градиент по всему обучающему набору: точно, но каждый шаг очень долгий
- Стохастический (SGD) берёт один случайный образец: шаги быстрые, но путь скачет вокруг минимума
- Мини-пакетный берёт небольшую случайную порцию: компромисс, хорошо ложится на матричные вычисления GPU
- Эпоха — один проход по всему набору: у пакетного спуска это один шаг, у SGD — m шагов по одному образцу; в примере книги SGD хватает 50 эпох, пакетному — 1000

ПУТИ ТРЁХ АЛГОРИТМОВ

- Пакетный идёт ровно и останавливается в минимуме, остальные бродят рядом
- Скачки гасят, уменьшая скорость обучения, — имитация отжига



По рис. 4.11 книги (стр. 171)

СРАВНЕНИЕ АЛГОРИТМОВ ДЛЯ ЛИНЕЙНОЙ РЕГРЕССИИ

Алгоритм	Большое m	Вне памяти	Большое n	Масштабирование
Нормальное уравнение	быстро	нет	медленно	не нужно
Пакетный спуск	медленно	нет	быстро	нужно
Стохастический спуск	быстро	да	быстро	нужно
Мини-пакетный спуск	быстро	да	быстро	нужно

- После обучения все алгоритмы дают очень похожие модели и прогнозируют одинаково

06

ИТОГИ

ОСТАТОК И ЦЕЛЕВАЯ ФУНКЦИЯ

- Остаток $e_i = y_i - \hat{y}_i$ — насколько модель промахнулась на одном образце, по вертикали
- Целевая функция собирает все остатки в одно число, которое оценивает модель целиком
- Обучение модели — поиск параметров, при которых целевая функция на обучающем наборе наименьшая

ПОЧЕМУ СУММА КВАДРАТОВ

- Квадраты не дают остаткам разных знаков взаимно уничтожиться
- Большие промахи штрафуются сильнее малых, а функция получается гладкой и выпуклой
- Гладкость даёт производные, выпуклость — единственный минимум без ловушек

КАК ПРОИЗВОДНЫЕ ДАЮТ ОТВЕТ

- Ручное решение: приравняли к нулю частные производные и решили систему из двух уравнений
- Нормальное уравнение: то же условие «градиент равен нулю», записанное матрицами для любого n
- Градиентный спуск: не решаем уравнение, а шагаем против градиента, пока он не станет почти нулевым
- Три пути — один ответ: $\hat{y} = 0{,}5x + 1/6$ и $S = 1/6$

07

ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. Почему складывают квадраты остатков, а не сами остатки?
2. Найдите оптимальные a и b для трёх точек через частные производные
3. Что будет при слишком большой и при слишком маленькой скорости обучения?
4. Какой алгоритм обучения выбрать, если признаков миллионы? (упр. 1, стр. 197)
5. Каким алгоритмам вредит разный масштаб признаков и что с этим делать? (упр. 2, стр. 197)

СПАСИБО ЗА ВНИМАНИЕ!

Данил Зитцер (d.k.zitcer@utmn.ru)



ivideon