Тюменский государственный университет ТюмГу | ivideon

ПОЛИНОМИАЛЬНАЯ РЕГРЕССИЯ, РЕГУЛЯРИЗАЦИЯ И ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

Лекция 05. Глава 4 «Обучение моделей»

Данил Зитцер (d.k.zitcer@utmn.ru)

СОДЕРЖАНИЕ

1. Линейные модели
2. Полиномиальная регрессия
3. Кривые обучения
4. Регуляризированные линейные модели
5. Логистическая регрессия
6. Итоги

01

ЛИНЕЙНЫЕ МОДЕЛИ

ЧТО ТАКОЕ ЛИНЕЙНАЯ МОДЕЛЬ

$$\hat{y} = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n = \theta^T \mathbf{x}$$

- Прогноз — взвешенная сумма признаков плюс свободный член
- «Линейная» — по параметрам θ, а не обязательно по исходным признакам
- Обучение — поиск θ, минимизирующих функцию стоимости, например MSE
- В лекции 04 три способа дали один ответ: вручную через частные производные, нормальным уравнением и градиентным спуском

ОДНА ОСНОВА, РАЗНЫЕ МОДЕЛИ

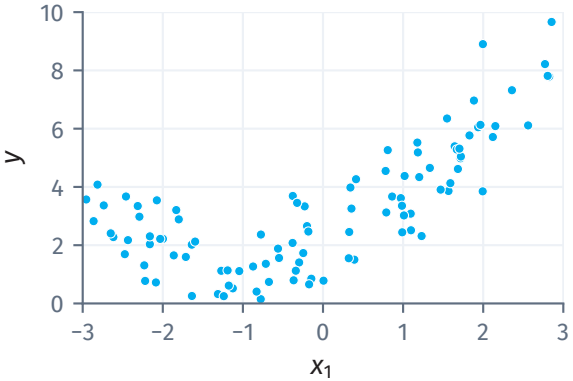


02

ПОЛИНОМИАЛЬНАЯ РЕГРЕССИЯ

НЕЛИНЕЙНЫЕ ДАННЫЕ

- 100 точек из $y = 0{,}5x_1^2 + x_1 + 2$ плюс шум
- Прямая систематически ошибается: на краях и в середине по-разному
- Нужна кривая, но обучать хочется линейной моделью



По рис. 4.12 книги (стр. 172)

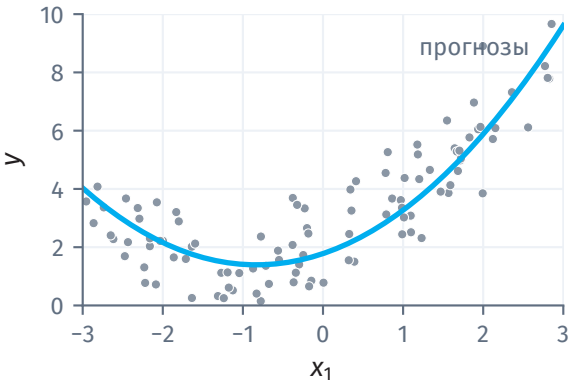
СТЕПЕНИ ПРИЗНАКА КАК НОВЫЕ ПРИЗНАКИ

$$x_1 \longrightarrow (x_1,\ x_1^2), \qquad \hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_1^2$$

- Квадрат признака объявляем ещё одним признаком
- На расширенном наборе обучаем обычную линейную регрессию
- Нелинейность — в признаках, модель линейна по θ
- Подходят нормальное уравнение и градиентный спуск

ПОДГОНКА ПАРАБОЛЫ

- Найдено:
  $\hat{y} = 0{,}56x_1^2 + 0{,}93x_1 + 1{,}78$
- Истина:
  $y = 0{,}5x_1^2 + 1{,}0x_1 + 2{,}0$
- Расхождение — от шума в 100 точках



По рис. 4.13 книги (стр. 173)

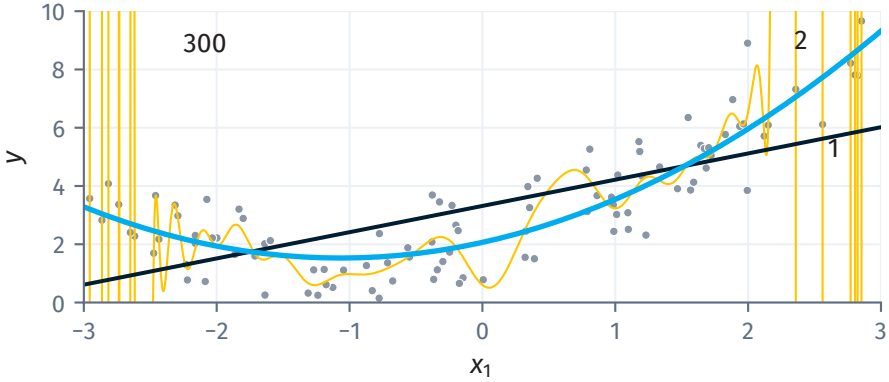
КОМБИНАЦИИ ПРИЗНАКОВ

- При нескольких признаках добавляются и их произведения — одночлены
- d ограничивает суммарную степень одночлена: a^2b при $d = 3$ годится ($2 + 1 = 3$), a^2b^2 — нет
- a, b при $d = 3$: $a^2, a^3, b^2, b^3, ab, a^2b, ab^2$
- Произведения ловят взаимодействие признаков
- Число одночленов растёт комбинаторно: $\frac{(n+d)!}{d!\,n!}$; 2 признака — 10, 100 признаков — 176 851

03

КРИВЫЕ ОБУЧЕНИЯ

СТЕПЕНИ 1, 2 И 300



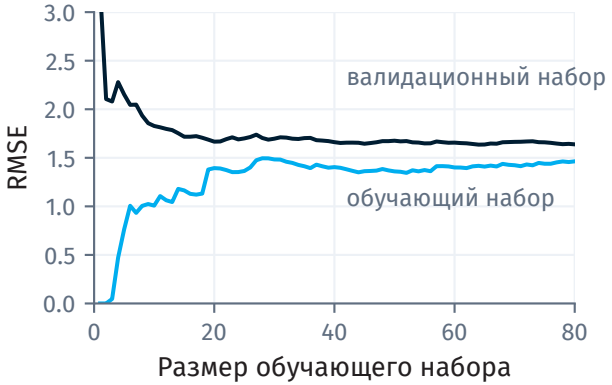
По рис. 4.14 книги (стр. 174)

КАК УЗНАТЬ, ЧТО МОДЕЛЬ СЛИШКОМ СЛОЖНА

- Перекрёстная проверка (глава 2): хорошо на обучении и плохо на проверке — переобучение; плохо везде — недообучение
- Кривые обучения — ошибка на обучающем и валидационном наборе от размера обучающего набора
- Строятся так: обучить на первых m образцах для $m = 1, 2, \ldots$ и замерить RMSE на них и на валидации

КРИВЫЕ ОБУЧЕНИЯ ПРЯМОЙ

- Обучающая ошибка с нуля растёт до плато
- Валидационная падает до плато
- Обе высоко и рядом — недообучение
- Больше данных не поможет: нужна сложнее модель или лучше признаки



По рис. 4.15 книги (стр. 176)

КРИВЫЕ ОБУЧЕНИЯ ПОЛИНОМА 10-Й СТЕПЕНИ

- Обучающая ошибка ниже, чем у прямой
- Промежуток между кривыми — переобучение
- С ростом набора кривые сближаются
- Лекарство: больше данных



По рис. 4.16 книги (стр. 177)

КАК ЧИТАТЬ КРИВЫЕ ОБУЧЕНИЯ

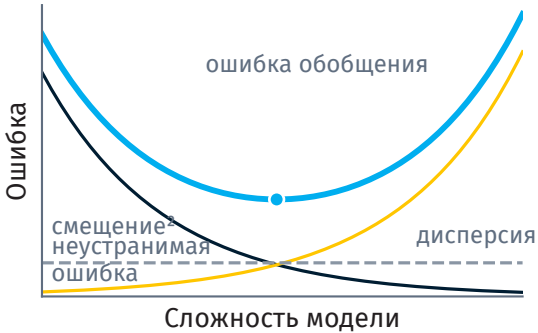
Картина	Диагноз	Что делать
Обе ошибки высокие и близкие	Недообучение	Сложнее модель, лучше признаки
Обучающая низкая, промежуток	Переобучение	Больше данных, проще модель, регуляризация
Обе низкие и близкие	Хорошая модель	—

КОМПРОМИСС СМЕЩЕНИЯ И ДИСПЕРСИИ

- Ошибку обобщения модели можно разложить на три составляющие:
- Смещение — от неверных допущений: «данные линейны», модель недообучается
- Дисперсия — от чувствительности к малым изменениям обучающих данных, модель переобучается
- Неустранимая ошибка — шум в данных, лечится только очисткой данных
- Сложнее модель — меньше смещение, больше дисперсия

СЛОЖНОСТЬ МОДЕЛИ И ОШИБКА

- Слева от минимума — недообучение
- Справа — переобучение
- Выбор модели — поиск минимума

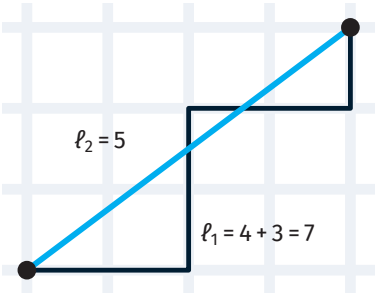


04

РЕГУЛЯРИЗИРОВАННЫЕ ЛИНЕЙНЫЕ МОДЕЛИ

НОРМЫ: КАК ИЗМЕРИТЬ ДЛИНУ ВЕКТОРА

- $\ell 2$, евклидова: $\sqrt{\sum v_i^2}$ — по прямой, основа RMSE
- $\ell 1$, манхэттенская: $\sum |v_i|$ — по кварталам, основа MAE
- Регуляризация штрафует норму вектора весов



ЗАЧЕМ ОГРАНИЧИВАТЬ ВЕСА

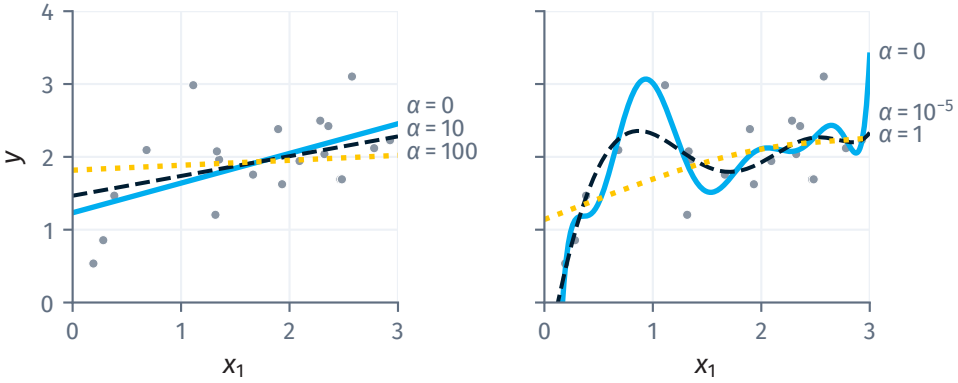
- Регуляризация — ограничение модели: меньше свободы — труднее переобучиться
- Полиному можно понизить степень — грубо
- Линейной модели ограничивают веса: гребневая регрессия ($\ell 2$), лассо ($\ell 1$), эластичная сеть ($\ell 1 + \ell 2$)
- Отдельный приём — ранняя остановка обучения

ГРЕБНЕВАЯ РЕГРЕССИЯ

$$J(\theta) = \mathrm{MSE}(\theta) + \alpha \frac{1}{2} \sum_{i=1}^{n} \theta_i^2$$

- Штраф $\ell 2$ держит веса малыми; α — сила регуляризации
- $\alpha = 0$ — обычная регрессия, $\alpha \to \infty$ — ровная линия через среднее
- θ_0 не штрафуется; штраф — $\frac{1}{2}\left(\|\mathbf{w}\|_2\right)^2$, половина квадрата нормы $\ell 2$
- Признаки обязательно масштабируют

ГРЕБНЕВАЯ РЕГРЕССИЯ НА ГРАФИКЕ



По рис. 4.17 книги (стр. 180)

РЕШЕНИЕ В ЗАМКНУТОЙ ФОРМЕ

$$\hat{\theta} = \left(\mathbf{X}^T\mathbf{X} + \alpha\mathbf{A}\right)^{-1}\mathbf{X}^T\mathbf{y}$$

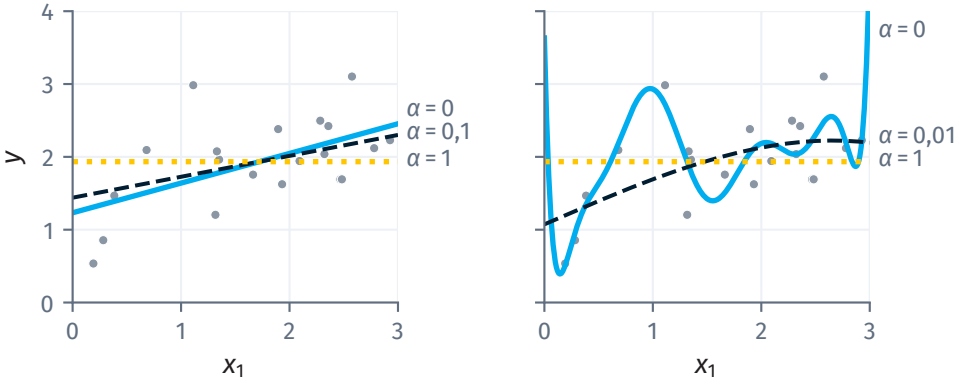
- $\mathbf{A}$ — единичная матрица с нулём в левом верхнем углу
- Нормальное уравнение плюс добавка $\alpha\mathbf{A}$
- Те же плюсы и минусы: при большом n медленно
- Альтернатива — градиентный спуск

ЛАССО-РЕГРЕССИЯ

$$J(\theta) = \mathrm{MSE}(\theta) + \alpha \sum_{i=1}^{n} |\theta_i|$$

- Штраф — норма ℓ1 вместо половины квадрата нормы ℓ2
- Обнуляет веса наименее важных признаков
- Сам отбирает признаки и даёт разреженную модель

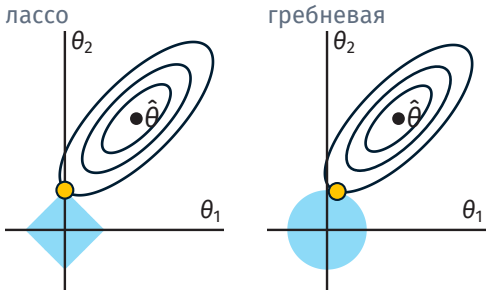
ЛАССО-РЕГРЕССИЯ НА ГРАФИКЕ



По рис. 4.18 книги (стр. 182)

ПОЧЕМУ ЛАССО ОБНУЛЯЕТ ВЕСА

- Штраф равносилен ограничению: $\|\theta\|_1 \le s$ — ромб, $\|\theta\|_2 \le s$ — круг
- Эллипсы — линии уровня MSE вокруг $\hat{\theta}$
- Решение — первая точка касания эллипса с областью
- У ромба углы на осях: касание в углу, $\theta_1 = 0$



По рис. 6.7 книги Гарета Джеймса и др. «An Introduction to Statistical Learning»

СУБГРАДИЕНТ

- В нуле модуль $|\theta_i|$ не дифференцируем
- Вместо производной берут знак веса: –1, 0 или +1
- $g(\theta, J) = \nabla_\theta \operatorname{MSE}(\theta) + \alpha \operatorname{sign}(\theta)$

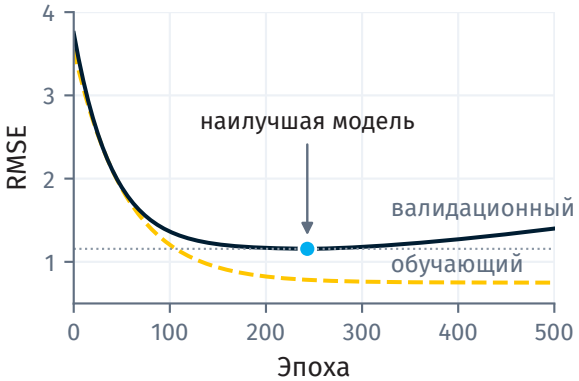
ЭЛАСТИЧНАЯ СЕТЬ

$$J(\theta) = \mathrm{MSE}(\theta) + r\alpha \sum_{i=1}^{n} |\theta_i| + \frac{1 - r}{2} \alpha \sum_{i=1}^{n} \theta_i^2$$

- Смесь штрафов ℓ1 и ℓ2: $r = 0$ — гребневая, $r = 1$ — лассо
- Хоть немного регуляризации нужно почти всегда
- Нет особых причин — начинайте с гребневой регрессии
- Полезны лишь немногие признаки — лассо или эластичная сеть
- Признаков больше, чем образцов, или они коррелируют — эластичная сеть, а не лассо

РАННЕЕ ПРЕКРАЩЕНИЕ

- Валидационная ошибка падает, потом растёт — началось переобучение
- Остановить обучение в минимуме валидационной ошибки
- При SGD кривая шумная: ждать, затем откатиться к лучшей точке



По рис. 4.20 книги (стр. 186)

05

ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

КЛАССИФИКАЦИЯ ЧЕРЕЗ РЕГРЕССИЮ

- Логистическая регрессия оценивает вероятность класса
- Пример: вероятность, что письмо — спам
- $\hat{p} > 50\,\%$ — класс «1», иначе — класс «0»
- Двоичный классификатор на основе взвешенной суммы

ОЦЕНИВАНИЕ ВЕРОЯТНОСТЕЙ

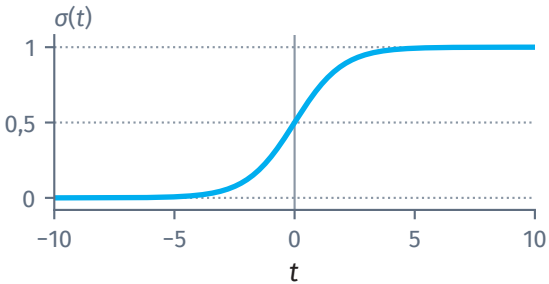
$$\hat{p} = h_\theta(\mathbf{x}) = \sigma(\theta^T \mathbf{x}), \qquad \hat{y} = \begin{cases} 0, & \hat{p} < 0{,}5 \\ 1, & \hat{p} \geq 0{,}5 \end{cases}$$

- Сначала взвешенная сумма $\theta^T \mathbf{x}$, как в линейной регрессии
- Затем логистическая функция σ превращает её в вероятность
- $\sigma(t) \geq 0{,}5$ ровно при $t \geq 0$: класс 1, когда $\theta^T \mathbf{x} \geq 0$

ЛОГИСТИЧЕСКАЯ ФУНКЦИЯ

$$\sigma(t) = \frac{1}{1 + \exp(-t)}$$

- S-образная кривая — сигмоида
- Любое число — в интервал (0, 1)
- $\sigma(0) = 0{,}5$

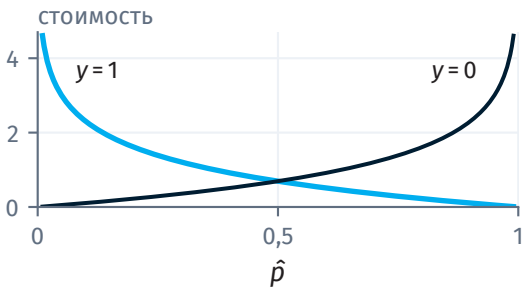


По рис. 4.21 книги (стр. 188)

ЦЕНА ОШИБКИ ОДНОГО ОБРАЗЦА

$$c(\theta) = \begin{cases} -\log(\hat{p}), & y = 1 \\ -\log(1 - \hat{p}), & y = 0 \end{cases}$$

- Уверенная ошибка стоит неограниченно дорого
- Уверенный верный ответ почти ничего не стоит



ЛОГАРИФМИЧЕСКАЯ ФУНКЦИЯ ПОТЕРЬ

$$J(\theta) = -\frac{1}{m}\sum_{i=1}^{m}\left[y^{(i)}\log\hat{p}^{(i)} + (1 - y^{(i)})\log(1 - \hat{p}^{(i)})\right]$$

- Среднее стоимостей по образцам; $y^{(i)}$ и $1 - y^{(i)}$ — переключатели
- Нормального уравнения нет
- Функция выпукла — градиентный спуск найдёт глобальный минимум

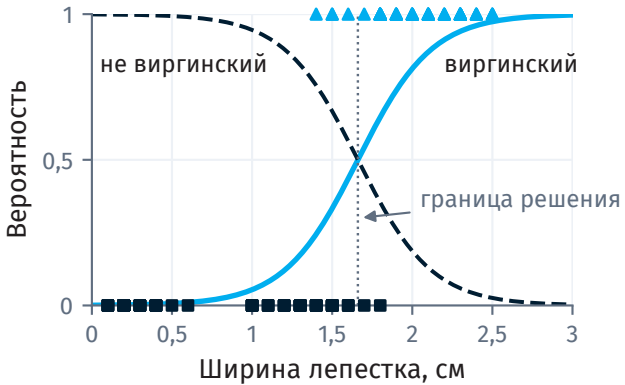
ГРАДИЕНТ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^{m} \left(\sigma(\theta^T \mathbf{x}^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

- Ошибка прогноза образца, умноженная на признак, среднее по образцам
- Та же форма, что у производной MSE линейной регрессии
- Пакетный, стохастический и мини-пакетный спуск — без изменений

ОДИН ПРИЗНАК: ШИРИНА ЛЕПЕСТКА

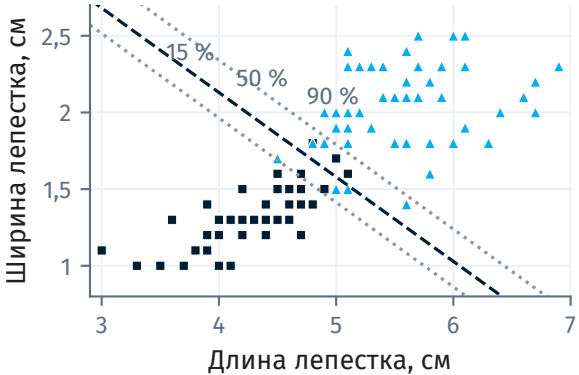
- Ирисы: щетинистый, разноцветный, виргинский
- Виргинский или нет — по ширине лепестка
- Выше 2 см и ниже 1 см модель уверена
- Граница решения — около 1,6 см



По рис. 4.23 книги (стр. 191)

ДВА ПРИЗНАКА: ЛИНЕЙНАЯ ГРАНИЦА

- Граница решения — прямая $\theta_0 + \theta_1 x_1 + \theta_2 x_2 = 0$
- Линии равной вероятности параллельны границе
- Регуляризация ℓ1 или ℓ2; в Scikit-Learn сила — $C = 1/\alpha$



По рис. 4.24 книги (стр. 193)

МНОГОПЕРЕМЕННАЯ ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

$$s_k(\mathbf{x}) = (\theta^{(k)})^T \mathbf{x}, \qquad \hat{p}_k = \frac{\exp(s_k(\mathbf{x}))}{\sum_{j=1}^{K} \exp(s_j(\mathbf{x}))}$$

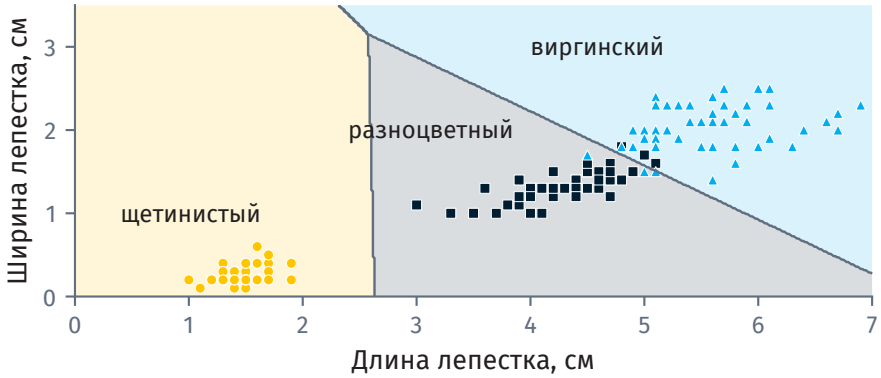
- Своя взвешенная сумма для каждого класса k
- Функция softmax превращает оценки в вероятности
- Прогноз — класс с наибольшей оценкой
- Многоклассовый, но не многовыходной: классы взаимоисключающие

ПЕРЕКРЁСТНАЯ ЭНТРОПИЯ

$$J(\Theta) = -\frac{1}{m}\sum_{i=1}^{m}\sum_{k=1}^{K} y_k^{(i)} \log \hat{p}_k^{(i)}$$

- Штрафует низкую вероятность правильного класса
- При $K = 2$ совпадает с логарифмической функцией потерь
- Градиент: $\frac{1}{m}\sum_i (\hat{p}_k^{(i)} - y_k^{(i)})\,\mathbf{x}^{(i)}$ — та же форма

ГРАНИЦЫ SOFTMAX-РЕГРЕССИИ



По рис. 4.25 книги (стр. 197)

06

ИТОГИ

ОДНА ОСНОВА, ПЯТЬ МОДЕЛЕЙ

Модель	Выход	Функция стоимости	Обучение
Полиномиальная	$\theta^T \mathbf{x}$ по расширенным признакам	MSE	норм. уравнение, ГС
Гребневая, лассо, эластичная сеть	$\theta^T \mathbf{x}$	MSE + штраф	ГС (гребневая — и формула)
Логистическая	$\sigma(\theta^T \mathbf{x})$	лог. функция потерь	ГС
Softmax	$\mathrm{softmax}(\Theta \mathbf{x})$	перекрёстная энтропия	ГС

НЕДООБУЧЕНИЕ И ПЕРЕОБУЧЕНИЕ: ЧТО ДЕЛАТЬ

- Недообучение: сложнее модель, лучше признаки, слабее регуляризация
- Переобучение: больше данных, проще модель, сильнее регуляризация, ранняя остановка
- Диагноз — по кривым обучения

07

ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. Почему полиномиальная регрессия — линейная модель?
2. Большой промежуток между кривыми обучения полинома: что произошло и три способа решения? (упр. 8, стр. 198)
3. Гребневая регрессия: обе ошибки высокие и близкие — смещение или дисперсия, увеличить α или уменьшить? (упр. 9, стр. 198)
4. Может ли градиентный спуск застрять в локальном минимуме у логистической регрессии? (упр. 3, стр. 197)
5. Почему лассо обнуляет веса, а гребневая регрессия — нет?

СПАСИБО ЗА ВНИМАНИЕ!

Данил Зитцер (d.k.zitcer@utmn.ru)



ivideon